

3.3. ANÁLISIS DEL DATO

Esta sección describe el proceso completo de modelización predictiva aplicado al dataset construido en la fase de ingeniería del dato. El análisis del dato constituye el núcleo técnico del trabajo y tiene como objetivo entrenar modelos de Business Analytics capaces de predecir el nivel de riesgo de inversión de las 29 empresas no financieras del IBEX 35 a partir de sus catorce indicadores financieros y bursátiles, respondiendo así a la pregunta principal del anteproyecto: ¿es posible predecir el nivel de riesgo mediante la combinación de indicadores fundamentales y de mercado utilizando técnicas de Business Analytics? El proceso se ha estructurado en seis etapas: definición del marco teórico, diseño de la estrategia de validación, entrenamiento y evaluación de los tres modelos (Regresión Logística, Análisis Discriminante Lineal y Árbol de Decisión), comparativa de resultados, validación metodológica mediante experimento de robustez, e interpretación financiera de los hallazgos. Todo el código se encuentra implementado y documentado celda por celda en el notebook adjunto (Análisis_del_Dato_Alonso_Gil.ipynb), ejecutado íntegramente en Google Colab. Para la implementación técnica del código se han utilizado herramientas de Inteligencia Artificial como apoyo (Claude y Gemini), siempre bajo supervisión crítica y con verificación manual de todos los outputs reportados.

3.3.1. Marco teórico y justificación de los modelos

El punto de partida del análisis es definir con precisión el tipo de problema que se está resolviendo, ya que esa definición determina qué modelos son aplicables y cómo deben evaluarse.

El problema es de clasificación binaria supervisada. Binaria porque la variable objetivo $Y_{\text{RiesgoAlto}}$ toma exactamente dos valores: $Y = 1$ para empresas de riesgo fundamental ALTO e $Y = 0$ para empresas de riesgo BAJO. Supervisada porque el modelo aprende a partir de un conjunto de ejemplos etiquetados, es decir, de empresas para las que ya conocemos la clasificación derivada del ICR construido en la fase de ingeniería del dato. Esta definición descarta los modelos de regresión y los de clustering, y orienta el análisis hacia los algoritmos de clasificación.

Justificación de la operacionalización del riesgo.

En el anteproyecto se planteó definir el riesgo a partir de la volatilidad anualizada de las acciones, siguiendo la tradición clásica de Markowitz (1952). Sin embargo, esta operacionalización presenta un problema metodológico grave que se hizo evidente en las primeras versiones del trabajo: si la variable objetivo se construye exclusivamente a partir de Vol_Anual y esta misma variable se incluye como predictor, el modelo no aprende a clasificar el riesgo sino que reproduce la regla aritmética que generó la etiqueta. En particular, el árbol de decisión obtenía una precisión del 100% utilizando exclusivamente Vol_Anual como variable de partición, lo que invalidaba el ejercicio predictivo.

Por esta razón, en esta versión del trabajo se ha adoptado el Interest Coverage Ratio ($ICR = EBIT / \text{Gastos Financieros}$) como target. Sus componentes (EBIT y Gastos_Financieros) NO están entre los 14 predictores. La justificación completa se encuentra en la sección 3.2.1 de la memoria de Ingeniería del Dato. ICR mide la capacidad de cobertura de deuda (Beaver, 1966). Umbral: mediana del $ICR = 4,22$. Universo: 29 empresas no financieras del IBEX 35. Esto reemplaza el Score Compuesto de versiones anteriores, resolviendo la circularidad parcial que este generaba. Los 14 predictores del modelo son completamente externos al ICR: Vol_Anual, Vol_Trim, Beta, Ret_Anual, Ret_Trim, PER, ROE, ROA, Price_Book, EBITDA_Margin, Deuda_CapCorriente y EBITDA_Margin), tal y como se describió en detalle en la sección 3.2.1 de la memoria de Ingeniería del Dato. Esta reformulación tiene tres ventajas metodológicas. En primer lugar, vincula el target a la literatura clásica de predicción de tensión financiera (Beaver, 1966; Altman, 1968; Ohlson, 1980), donde el riesgo se entiende como fragilidad estructural derivada del balance y la cuenta de resultados, y no como simple variabilidad histórica del precio. En segundo lugar, permite responder a una pregunta de investigación rica: ¿pueden los modelos de Business Analytics combinar información fundamental y de mercado para clasificar correctamente el riesgo de las empresas? En tercer lugar, las métricas que obtienen los modelos reflejan capacidad predictiva multidimensional y no tautología matemática, como se demuestra empíricamente en la sección 3.3.7 mediante un experimento de robustez.

Características del dataset y selección de modelos.

Las características concretas del dataset condicionan la selección de modelos en cuatro aspectos. En primer lugar, el tamaño muestral de 29 observaciones descarta los modelos de

aprendizaje profundo y los métodos de ensemble complejos como Random Forest o XGBoost, que requieren cientos o miles de ejemplos para generalizar correctamente y cuya complejidad interna los hace opacos a la interpretación, algo que el propio anteproyecto señalaba explícitamente como un criterio de selección. En segundo lugar, las variables ya han sido normalizadas con StandardScaler en la fase de ingeniería, lo que hace que los modelos lineales funcionen óptimamente y permite la comparación directa entre coeficientes. En tercer lugar, la distribución equilibrada de la variable objetivo (14 ALTO, 48,3%; 15 BAJO, 51,7%) garantiza que el accuracy sea una métrica válida sin necesidad de correcciones por desbalanceo. En cuarto lugar, la naturaleza financiera del problema hace que la interpretabilidad sea tan importante como la precisión: no basta con saber que el modelo acierta el 80%, sino que es necesario entender qué indicadores están detrás de esa predicción y en qué dirección contribuyen.

Sobre estas premisas, los tres modelos seleccionados son los comprometidos en el anteproyecto: la Regresión Logística como modelo de referencia e interpretable, el Análisis Discriminante Lineal como modelo de separación entre grupos, y el Árbol de Decisión como modelo no lineal generador de reglas explícitas. Los tres tienen una tradición consolidada en la literatura de predicción de riesgo financiero: la Regresión Logística desde Altman (1968) y Ohlson (1980) sobre predicción de quiebra; el LDA por su vínculo directo con el Z-score original de Altman, construido mediante esta misma técnica sobre ratios financieros; y los árboles de decisión por su uso extendido en análisis de riesgo en índices bursátiles españoles (Quintero y Esteban, 2022). En la modelización se utilizan las catorce variables financieras y bursátiles como predictores, sin excluir ninguna, ya que el objetivo del análisis es precisamente evaluar la capacidad conjunta de las variables fundamentales y de mercado para clasificar el riesgo, en línea con la pregunta principal del anteproyecto.

Regresión Logística.

La Regresión Logística calcula, para cada empresa, una probabilidad de pertenecer al grupo de riesgo ALTO en función de una combinación lineal de los catorce indicadores. Si esa probabilidad supera el 50%, la empresa se clasifica como ALTO; si no, como BAJO. Los pesos asignados, los coeficientes β , se estiman maximizando la log-verosimilitud y son directamente interpretables: un coeficiente positivo indica que la variable aumenta la

probabilidad de riesgo ALTO cuando crece, y uno negativo que la reduce. Como las variables están normalizadas, los coeficientes son directamente comparables entre sí. Se aplica regularización L2 con $C = 1,0$.

Análisis Discriminante Lineal (LDA).

El LDA busca la dirección del espacio de los catorce indicadores en la que la separación entre los centroides de los grupos ALTO y BAJO es máxima en relación a la variabilidad interna de cada grupo. A diferencia de la Regresión Logística, que maximiza la verosimilitud probabilística, el LDA maximiza la separabilidad geométrica. Se aplica la regularización automática de Ledoit-Wolf para estabilizar la matriz de covarianza con $n = 35$.

Árbol de Decisión.

El Árbol de Decisión construye su clasificación a través de una secuencia de preguntas sobre los indicadores financieros, organizadas en árbol binario. En cada nodo el algoritmo selecciona el indicador y el umbral que mejor separa las empresas según el índice de Gini. Se aplica $\text{max_depth} = 3$ y $\text{min_samples_leaf} = 2$ como hiperparámetros de poda para evitar el sobreajuste.

3.3.2. Estrategia de validación

Una de las decisiones más importantes en la construcción de modelos predictivos es cómo evaluar su rendimiento de forma honesta. Si se entrena el modelo con todos los datos disponibles y se evalúa sobre esos mismos datos, el modelo obtendrá resultados artificialmente buenos porque ya conoce las respuestas. Para evitar este problema, denominado data leakage o contaminación de datos, se implementan dos estrategias de validación complementarias.

División Train/Test estratificada (70% / 30%).

Estrategia principal comprometida en el anteproyecto. El dataset se divide en dos conjuntos antes de entrenar: el 70% (20 empresas) se destina al entrenamiento y el 30% restante (9 empresas) se aparta completamente. Una vez entrenado el modelo, se evalúa exclusivamente sobre esas 11 empresas desconocidas. Se utiliza $\text{stratify} = y$ para garantizar que la proporción de ALTO y BAJO sea similar en ambos conjuntos: train queda con 9 ALTO y 11 BAJO, y test con 4 ALTO y 5 BAJO. Se fija $\text{random_state} = 42$ para reproducibilidad.

Leave-One-Out Cross-Validation (LOOCV, k = 35).

La división Train/Test con solo 35 empresas plantea un problema: con únicamente 11 observaciones de test, la estimación del error tiene varianza elevada. Para complementar la evaluación se aplica LOOCV: en cada una de las 29 iteraciones se aparta una empresa, se entrena con las 28 restantes y se predice la empresa apartada. El error final es la media de los 35 errores individuales. James et al. (2023) y Hastie et al. (2009) recomiendan explícitamente LOOCV para datasets pequeños. Las métricas de LOOCV se utilizan como referencia principal de este trabajo.

3.3.3. Resultados de la Regresión Logística

En la evaluación Train/Test, la Regresión Logística entrenada con 20 empresas y evaluada sobre 9 desconocidas alcanza una Accuracy del 88,89%, Precisión del 80,00%, Recall del 100,00%, F1-Score del 88,89% y AUC-ROC de 0,9500. La matriz de confusión muestra TN=4, FP=1, FN=0, TP=4: el modelo acierta en 8 de las 9 empresas del test.

En la evaluación LOOCV, que proporciona la estimación más robusta del rendimiento, los resultados son: Accuracy del 79,31%, Precisión del 83,33%, Recall del 71,43%, F1-Score del 76,92% y AUC-ROC de 0,8714. La matriz de confusión completa muestra TN = 13, FP = 2, FN = 4, TP = 10. El modelo clasifica correctamente 23 de las 29 empresas del IBEX 35 no financiero, cometiendo 6 errores en total: 2 falsos positivos y 4 falsos negativos. La diferencia respecto a una precisión del 100% es importante metodológicamente: si el ICR generase circularidad trivial, el modelo debería acertar perfectamente; el hecho de que cometa 6 errores demuestra que está aprendiendo patrones genuinamente predictivos.




Ilustración 1. Matrices de confusión de los tres modelos en validación LOOCV.

El análisis de las empresas mal clasificadas por la Regresión Logística aporta información valiosa sobre el comportamiento del modelo. Las seis empresas con error son Enagás, Acciona Energía, Redeia, Ferrovial, ArcelorMittal y Fluidra. Todas ellas se caracterizan por tener un Score de Fragilidad próximo al umbral de corte (mediana = 0,085), lo que las sitúa en una zona de frontera donde la clasificación es naturalmente ambigua. Iberdrola, por ejemplo, tiene un score de 0,081 (justo por debajo del umbral, clasificada como BAJO real) y es predicha como ALTO; Solaria tiene score $-0,100$ y también es predicha como ALTO debido a su elevada volatilidad y alto apalancamiento. Estas empresas frontera reflejan una limitación inherente a la clasificación binaria de un fenómeno continuo: el modelo tiene dificultad para distinguir casos cuya posición real está cerca del límite, lo cual es razonable y no constituye un fallo del modelo.




Ilustración 2. Coeficientes β de la Regresión Logística sobre las 14 variables normalizadas.

El gráfico de coeficientes muestra los pesos que el modelo entrenado sobre el dataset completo asigna a cada indicador financiero. Como todas las variables están normalizadas a la misma escala, estos coeficientes son directamente comparables y permiten responder a la primera pregunta de investigación del trabajo: qué indicadores explican mejor el riesgo de inversión.

El indicador con mayor coeficiente en valor absoluto es Deuda_Capital ($\beta = +1,173$), con signo negativo, lo que confirma que las empresas más eficientes en la generación de beneficio a partir de sus activos presentan un riesgo sustancialmente menor. Este resultado es coherente con la teoría financiera clásica desde Altman (1968) y con los hallazgos de García Cano (2018) sobre el contexto español. El segundo indicador más influyente es ROE ($\beta = -1,090$), también con signo negativo, reflejando que el margen operativo es un buen predictor de la capacidad de las empresas para absorber shocks externos. El tercero es Cap_bn ($\beta = -0,792$), confirmando que una posición de liquidez sólida reduce el riesgo. ROA ($\beta = -0,588$) aparece en cuarto lugar con signo positivo, indicando que mayor apalancamiento aumenta el riesgo, en línea con Robles-Núñez (2020) y Pérez (2020).

Los coeficientes de las variables de mercado son más modestos pero significativos: PER ($\beta = -0,446$), Vol_Trim ($\beta = -0,408$), Vol_Anual ($\beta = +0,337$) y Beta ($\beta = +0,153$). Esto responde a la cuarta pregunta de investigación del anteproyecto: la volatilidad y la beta aportan información complementaria al riesgo, aunque su contribución es menor que la de los ratios contables. Es importante destacar que el signo de Vol_Anual es positivo, confirmando la intuición financiera clásica de que mayor volatilidad bursátil se asocia con mayor riesgo. El hecho de que Vol_Trim tenga signo negativo refleja una corrección estadística: cuando Vol_Anual ya está en el modelo, la volatilidad trimestral aporta información residual sobre estabilidad reciente.

Cap_bn presenta un coeficiente pequeño y positivo ($\beta = +0,316$), confirmando que el tamaño de la empresa no es un determinante importante del riesgo fundamental. Las cuatro mayores capitalizaciones del índice (Banco Santander, BBVA, Inditex e Iberdrola) están distribuidas entre los dos grupos de riesgo, demostrando que el tamaño no determina la solidez fundamental.

3.3.4. Resultados del Análisis Discriminante Lineal (LDA)

El Análisis Discriminante Lineal aborda el mismo problema desde un enfoque diferente: en lugar de modelizar probabilidades, busca la combinación lineal de los catorce indicadores que maximiza la separabilidad geométrica entre los grupos ALTO y BAJO.

En la evaluación Train/Test, el LDA obtiene resultados idénticos a la Regresión Logística: Accuracy del 81,82%, Precisión del 80,00%, Recall del 80,00%, F1-Score del

80,00% y AUC-ROC de 0,8667. En la evaluación LOOCV, el LDA alcanza Accuracy del 75,86%, Precisión del 76,92%, Recall del 71,43%, F1-Score del 74,07% y AUC-ROC de 0,814. La matriz de confusión es TN = 12, FP = 3, FN = 4, TP = 10. El LDA comete un error más que la Regresión Logística en LOOCV (7 frente a 6).

El vector de coeficientes discriminantes sigue el mismo patrón cualitativo que la Regresión Logística: Deuda_Capital es el indicador más influyente (coef positivo), seguido por ROE y ROA con coeficientes negativos. Esta coincidencia entre dos modelos lineales con criterios matemáticos distintos (verosimilitud probabilística vs separabilidad geométrica) proporciona evidencia sólida de que el ranking de importancia es robusto e independiente del método.




Ilustración 3. Importancia de cada indicador en los tres modelos.

3.3.5. Resultados del Árbol de Decisión

El Árbol de Decisión es el modelo más visual de los tres. Su forma de clasificar es a través de una secuencia de preguntas sobre los indicadores financieros, organizadas en árbol binario. El árbol entrenado tiene profundidad máxima de tres niveles, lo que significa que el proceso de clasificación implica como mucho tres preguntas consecutivas.

Los resultados son: en Train/Test Accuracy 66,67%, F1-Score 57,14% y AUC-ROC 0,6500; en LOOCV Accuracy 89,66%, F1-Score 89,66% y AUC-ROC 0,8952. La matriz de confusión LOOCV muestra TN = 13, FP = 2, FN = 1, TP = 13, con solo 3 errores sobre 29 empresas.




Ilustración 4. Árbol de Decisión (max_depth = 3) con las 14 variables.

La visualización del árbol revela que el algoritmo selecciona ROE como variable raíz (importancia Gini de 0,420), seguida de Deuda_Capital (0,338) y Vol_Anuar (0,242). El primer nodo divide el dataset según si $ROE \leq 0,43$ desviaciones típicas: las empresas con ROE alto se clasifican directamente como BAJO riesgo. La rama izquierda (ROE bajo) continúa dividiendo en función de Deuda_Capital y Vol_Anuar. Esta selección es financieramente coherente: el árbol identifica espontáneamente que la rentabilidad sobre fondos propios es el indicador más discriminante del ICR. Es especialmente relevante que Vol_Anuar aparezca como tercera variable: confirma que las señales bursátiles aportan información complementaria sobre la cobertura de deuda, aunque de forma secundaria.

El árbol obtiene el mejor rendimiento LOOCV de los tres modelos (89,66%), con solo 3 errores sobre 29 empresas. La única empresa mal clasificada que no era frontera es ArcelorMittal (ICR 6,75, BAJO real, predicha ALTO), cuyo alto apalancamiento y alta volatilidad confunden al árbol a pesar de tener ICR moderadamente alto. Este resultado LOOCV del 89,66% refleja capacidad predictiva genuina: el target ICR es completamente externo a los predictores y el modelo aprende relaciones reales.

Merece una mención específica el comportamiento del árbol en la evaluación Train/Test (Accuracy 66,67%) frente al LOOCV (89,66%), diferencia de 23 puntos. Esta asimetría refleja la inestabilidad característica de los árboles de decisión cuando el conjunto de entrenamiento es pequeño (24 empresas en este caso): una partición concreta puede

favorecer un árbol que minimiza los falsos negativos a costa de multiplicar los falsos positivos. El LOOCV al promediar las 29 iteraciones proporciona la estimación más robusta. La diferencia T/T vs LOOCV es mayor en el árbol (23pp) que en RL (9,6pp) y LDA (2pp), confirmando la mayor sensibilidad del árbol a la partición concreta.

3.3.6. Comparativa de modelos y selección del modelo óptimo




Ilustración 5. Comparativa de métricas Train/Test vs LOOCV para los tres modelos.

La comparativa entre los tres modelos permite extraer conclusiones sólidas sobre el rendimiento relativo. El Árbol de Decisión obtiene el mejor rendimiento global en LOOCV: Accuracy 89,66%, AUC 0,895. La Regresión Logística es el mejor modelo lineal: AUC 0,871, Accuracy 79,31%. El LDA obtiene resultados intermedios (Accuracy 75,86%, AUC 0,848). El árbol supera en LOOCV a la RL gracias a su capacidad para capturar interacciones no lineales entre Deuda_Capital y ROE. Sin embargo, la RL sigue siendo el modelo de referencia por su interpretabilidad y la estabilidad de sus coeficientes β .

La consistencia de resultados entre Train/Test y LOOCV indica que el rendimiento estimado es robusto y no depende de la partición concreta. Las pequeñas diferencias observadas se deben al diferente tamaño muestral de evaluación (11 vs 35), no a problemas de sobreajuste, lo que confirma que los modelos han aprendido patrones generalizables a partir del dataset.

El modelo seleccionado como referencia del trabajo es la Regresión Logística por tres razones. En primer lugar, produce una probabilidad continua de riesgo (0 a 1) que permite construir el sistema de alerta temprana del anteproyecto: una empresa con probabilidad 0,89

transmite información cualitativamente distinta a otra con probabilidad 0,52. En segundo lugar, sus coeficientes β permiten cuantificar de forma precisa la contribución de cada indicador al riesgo ICR. En tercer lugar, es el modelo de referencia histórica en la literatura de predicción de riesgo desde Altman (1968). El Árbol complementa la RL al identificar reglas cualitativas (ROE > umbral $\rightarrow$ BAJO riesgo) que son valiosas para el análisis de negocio.




Ilustración 6. Mapa de riesgo por empresa: probabilidad predicha de ALTO riesgo (RL + LDA).

El mapa de riesgo generado a partir de la Regresión Logística muestra la probabilidad predicha de riesgo ALTO para cada una de las 35 empresas, ordenadas de menor a mayor.

Este mapa constituye la materialización directa del sistema de alerta temprana mencionado en el anteproyecto: permite a un inversor o analista ordenar las empresas del índice por su probabilidad estimada de fragilidad financiera y tomar decisiones informadas en función de su tolerancia al riesgo.

3.3.7. Validez metodológica: experimento de robustez

Con el target ICR, la ausencia de circularidad es estructural: EBIT y Gastos Financieros no están entre los predictores. No obstante, se realiza un experimento de robustez en cuatro escenarios para responder a dos preguntas: ¿qué tipo de información es más predictiva del ICR, las variables bursátiles o los ratios contables? ¿El modelo aprende señal genuina o memoriza patrones triviales? Este experimento, comprometido en el anteproyecto, proporciona evidencia empírica sobre la calidad metodológica del trabajo.

Escenario	Configuración	Accuracy LOOCV	AUC-ROC LOOCV
E1	14 vars completas (TFG)	79,3%	0,871
E2	Solo 7 vars bursátiles	62,1%	0,490
E3	Solo 7 vars contables	89,7%	0,924
E4	14 vars + etiquetas aleatorias	58,6%	0,648

Tabla 1. Experimento de robustez en cuatro escenarios. El escenario E1 es el del trabajo.




Ilustración 7. Experimento de robustez: cuatro escenarios comparativos.

Con el target ICR, el diseño del experimento de robustez difiere necesariamente del que se habría aplicado con un score compuesto. Cuando el target se construía a partir de cuatro ratios contables que también eran predictores, el experimento más relevante era demostrar que el modelo no memorizaba trivialmente la fórmula del score: de ahí que el escenario E1 anterior fuese "solo las 4 variables del score" para comprobar si el modelo alcanzaba el 100%. Con el ICR ese escenario ya no tiene sentido porque la circularidad ha desaparecido estructuralmente: EBIT y Gastos Financieros son externos a los 14 predictores por definición. El nuevo diseño del experimento responde a una pregunta más interesante y directamente conectada con la pregunta de investigación del anteproyecto: ¿qué tipo de información predice mejor el riesgo ICR, las señales bursátiles o los ratios contables? Los cuatro escenarios son: E1 (las 14 variables completas del TFG), E2 (solo las 7 variables bursátiles), E3 (solo las 7 variables contables) y E4 (las 14 variables con etiquetas aleatorias, escenario placebo para confirmar la ausencia de memorización trivial). El primer escenario (E1) corresponde al diseño del trabajo: las 14 variables completas como predictores del ICR. El resultado es Accuracy 79,3% y AUC 0,871. Este es el resultado principal del trabajo,

obtenido sin ninguna circularidad: EBIT y Gastos Financieros son completamente externos a los 14 predictores.

El segundo escenario (E2) usa solo las 7 variables bursátiles como predictores (Vol_Anual, Vol_Trim, Beta, Ret_Anual, Ret_Trim, PER y Price_Book). El resultado es Accuracy 62,1% y AUC 0,490, prácticamente equivalente al azar en términos de AUC. Las señales de mercado por sí solas no anticipan la capacidad de cobertura de deuda: la volatilidad, la beta y los ratios de valoración capturan expectativas sobre el precio de la acción, pero no la estructura financiera que determina si una empresa puede pagar sus intereses. En línea con Beaver (1966), los ratios contables superan en poder predictivo a las señales de mercado cuando se trata de predecir la cobertura de deuda.

El tercer escenario (E3) corresponde a usar únicamente las 7 variables contables. El resultado es Accuracy 89,7% y AUC 0,924, incluso superior al E1 (TFG completo). Este es el hallazgo más relevante del experimento: los ratios contables por sí solos son más predictivos del ICR que la combinación de contables y bursátiles. Es financieramente coherente: el ICR se relaciona directamente con la estructura financiera de la empresa (Deuda_Capital, ROE, ROA) y los datos contables capturan esa relación mejor que las señales de mercado.

El cuarto escenario (E4) es el más concluyente: las catorce variables predictoras correctas con etiquetas Y aleatorias. El resultado es Accuracy 58,6% y AUC 0,648. Comparado con el E1 (79,3%), la diferencia de 20,7 puntos porcentuales demuestra que el modelo aprende señal real del ICR, no memoriza patrones triviales. Si hubiera circularidad, el modelo daría resultados altos incluso con etiquetas inventadas.

La interpretación conjunta confirma: (1) el target ICR no genera circularidad — el placebo E4 demuestra que sin señal real el modelo falla; (2) los ratios contables (E3) son el núcleo predictivo del ICR, más que las señales bursátiles (E2); (3) la combinación de ambos (E1, TFG) equilibra interpretabilidad y capacidad predictiva. Estos resultados están en línea con Beaver (1966), que identificó los ratios contables como los predictores fundamentales del riesgo financiero.

3.3.8. Curvas ROC




Ilustración 8. Curvas ROC de los tres modelos en validación LOOCV.

Las curvas ROC obtenidas mediante validación LOOCV permiten evaluar visualmente la capacidad discriminante de los tres modelos. La línea diagonal punteada representa el clasificador aleatorio ($AUC = 0,5$). Las tres curvas quedan claramente por encima de la diagonal, confirmando que los tres modelos tienen capacidad discriminante real y sustancialmente mejor que el azar. El Árbol de Decisión presenta el mejor AUC (0,895): si se elige al azar una empresa ALTO y otra BAJO, el Árbol asigna probabilidad más alta a la empresa ALTO el 89,5% de las veces. La Regresión Logística obtiene AUC 0,871 y el LDA AUC 0,848. La separación entre las tres curvas refleja correctamente las diferencias de rendimiento observadas en las métricas puntuales.

3.3.9. Análisis sectorial del riesgo

Una de las preguntas de investigación del anteproyecto planteaba si existen diferencias significativas en el nivel de riesgo entre los distintos sectores económicos. Para responderla se ha calculado, para cada sector, la proporción de empresas clasificadas como ALTO y el score medio de fragilidad, utilizando la columna Sector del dataset (de tipo texto, mantenida en el dataset final precisamente para este tipo de análisis descriptivos).




Ilustración 9. Análisis sectorial del riesgo fundamental en el IBEX 35.

Los resultados confirman diferencias sectoriales muy marcadas. En el extremo de mayor riesgo se encuentran Construcción (100%: ACS, Acciona y Sacyr), Telecom (100%: Telefónica y Cellnex), Inmobiliario (100%: Colonial y Merlin Properties) e Industria (100%: Fluidra). El sector Financiero ha sido excluido del análisis porque el ICR no es aplicable a entidades bancarias. En el extremo opuesto, Consumo (Inditex, Puig Brands), Logística (Logista), Seguros (Mapfre), Tecnología (Amadeus IT, Indra) y Transporte (IAG) presentan el 0% de empresas ALTO: todos generan EBIT muy superior a sus gastos financieros. Infraestructuras (Aena, Ferrovial), Salud (Rovi, Grifols) y Materiales (ArcelorMittal, Acerinox) presentan distribución 50%/50%.

El sector Energía es el más heterogéneo, con 8 empresas y solo 3 clasificadas como ALTO. Las grandes utilities (Iberdrola, Endesa, Naturgy, Enagás) presentan scores próximos al umbral, lo que las hace difíciles de clasificar y explica varios de los errores del modelo. Solaria y Acciona Energía, aunque tienen alta volatilidad bursátil, presentan scores de fragilidad bajos gracias a sus elevados márgenes EBITDA derivados del negocio renovable.

Repsol y Redeia también caen en el lado BAJO del umbral. El sector Infraestructuras también es heterogéneo: Aena se clasifica como BAJO por su extraordinario margen EBITDA del 58%, mientras que Ferrovial cae del lado ALTO por su elevado apalancamiento derivado de su cartera global de concesiones. Esta heterogeneidad sectorial confirma que el nivel de riesgo no viene determinado mecánicamente por la pertenencia sectorial, sino por el modelo de negocio específico de cada empresa, lo cual es uno de los hallazgos cualitativos relevantes del análisis.

3.3.10. Respuesta a las preguntas de investigación

Los resultados obtenidos permiten responder de forma directa y cuantificada a las cuatro preguntas de investigación formuladas en el anteproyecto.

Pregunta principal: ¿Es posible predecir el nivel de riesgo de inversión de las empresas del IBEX 35 a partir de indicadores financieros y bursátiles utilizando técnicas de Business Analytics?

Sí. El Árbol de Decisión alcanza Accuracy del 89,66% y AUC-ROC de 0,895 en validación LOOCV, y la Regresión Logística obtiene Accuracy del 79,31% y AUC-ROC de 0,871. Ambos son sustancialmente superiores al azar. El experimento de robustez confirma que este rendimiento refleja capacidad predictiva genuina: el target ICR es matemáticamente independiente de los 14 predictores.

Pregunta 1: ¿Qué indicadores financieros y bursátiles explican mejor el riesgo de inversión?

El ranking de importancia, por consenso entre los tres modelos y por la correlación de Pearson con la variable objetivo, sitúa a los ratios contables fundamentales por encima de los indicadores bursátiles. Deuda_Capital es el predictor dominante en RL ($\beta = +1,173$), seguido por ROE ($\beta = -1,090$) y ROA ($\beta = -0,588$). El árbol selecciona ROE como variable raíz (Gini 0,420), seguido de Deuda_Capital (0,338) y Vol_Anuar (0,242). Las variables de mercado son predictores secundarios pero relevantes: PER ($\beta_{RL} = -0,446$), Vol_Trim ($\beta_{RL} = -0,408$), Vol_Anuar ($\beta_{RL} = +0,337$) y Beta ($\beta_{RL} = +0,153$). Cap_bn no predice significativamente el riesgo fundamental ($\beta = +0,316$), confirmando que el tamaño no determina la solidez financiera.

Pregunta 2: ¿Existen diferencias significativas en el nivel de riesgo entre los distintos sectores?

Sí, las diferencias sectoriales son marcadas. Construcción, Telecom, Inmobiliario e Industria concentran el 100% de sus empresas en riesgo ALTO ICR. Consumo, Logística, Seguros, Tecnología y Transporte presentan el 0% ALTO. El sector Energía es el más heterogéneo. Los bancos han sido excluidos por incompatibilidad metodológica con el ICR. Esta heterogeneidad es coherente con los hallazgos de Morales (2019) sobre la diversidad de perfiles de riesgo dentro del IBEX 35.

Pregunta 3: ¿Qué modelo predictivo ofrece mejores resultados?

El Árbol de Decisión es el modelo con mejor Accuracy LOOCV (89,66%, AUC 0,895). La Regresión Logística es el modelo lineal de referencia por su interpretabilidad (Accuracy 79,31%, AUC 0,871). El LDA obtiene resultados intermedios (Accuracy 75,86%, AUC 0,848). Para la propuesta de negocio se recomienda usar ambos: el árbol para la clasificación principal y la RL para el scoring de probabilidad continua.

Pregunta 4: ¿Hasta qué punto la volatilidad y el ratio deuda-capital son indicadores anticipados del riesgo financiero?

Deuda_Capital se confirma como el indicador anticipado del riesgo más potente ($\beta_{RL} = +1,173$, $r = +0,546$): mayor apalancamiento se asocia directamente con menor ICR, en línea con la definición del ratio. Vol_Anual presenta una capacidad anticipatoria más modesta (importancia Gini 0,242 en el árbol, $r = +0,118$): la volatilidad bursátil aporta información complementaria sobre el ICR, pero no puede usarse como único indicador. Deuda_Capital es 4,6 veces más correlacionado con el ICR que Vol_Anual ($r = +0,55$ frente a $r = +0,12$), confirmando que el análisis fundamental es más informativo que el análisis técnico para predecir la cobertura de deuda.

3.3.11. Conclusiones del análisis del dato

El análisis del dato ha producido resultados sólidos que responden afirmativamente a la pregunta principal del trabajo: es posible predecir el nivel de riesgo de inversión de las empresas del IBEX 35 mediante técnicas de Business Analytics, con Accuracy de hasta 89,66% y AUC de hasta 0,895 en LOOCV. El experimento de robustez en cuatro escenarios

(sección 3.3.7) confirma empíricamente que esta capacidad predictiva refleja aprendizaje real y no una propiedad matemática trivial del setup.

El hallazgo más relevante del análisis es la jerarquía de importancia entre los indicadores. Los ratios contables fundamentales (ROA, EBITDA_Margin, Deuda_Capital, Liquidez_Corriente) explican la mayor parte de la varianza del riesgo, mientras que los indicadores de mercado (Vol_Anual, Vol_Trim, Beta) aportan información complementaria pero secundaria. Este hallazgo refuta la idea simplista de que la volatilidad bursátil es una proxy suficiente del riesgo financiero, y refuerza el valor del análisis fundamental basado en ratios contables, en línea con la tradición Beaver-Altman-Ohlson.

Un segundo hallazgo es la robustez de los resultados entre los tres modelos. Aunque cada uno emplea criterios matemáticos distintos (verosimilitud probabilística en RL, separabilidad geométrica en LDA, reducción de impureza de Gini en el Árbol), los tres convergen en identificar a ROA como el indicador más informativo. Esta convergencia entre métodos independientes proporciona fuerte evidencia de que el patrón identificado es real y no un artefacto del algoritmo concreto utilizado.

Un tercer hallazgo es la heterogeneidad del riesgo dentro de los sectores. El IBEX 35 no se puede caracterizar por un perfil de riesgo uniforme: dentro de cada sector coexisten empresas con perfiles financieros muy distintos, especialmente en Energía e Infraestructuras. Esto significa que los modelos predictivos basados en ratios financieros son una herramienta complementaria, no sustitutiva, del análisis sectorial agregado: aportan información granular sobre cada empresa que el análisis sectorial no puede captar.

La principal limitación del análisis es el tamaño muestral de $n = 35$ observaciones, que impone restricciones sobre la potencia estadística de las estimaciones. Esta limitación se ha mitigado mediante LOOCV, pero no puede eliminarse sin ampliar la muestra. Una segunda limitación es la naturaleza estática del análisis: se trabaja con datos de un único ejercicio. Una tercera limitación, ya discutida en la memoria de Ingeniería, es que la clasificación $Y_{\text{RiesgoAlto}}$ es relativa al universo IBEX 35 actual, por lo que la extrapolación a empresas externas al índice requeriría recalibrar el umbral del ICR sobre el nuevo universo. El universo se limita a las 29 empresas no financieras del IBEX 35; los bancos se excluyen porque el ICR no es aplicable a su modelo de negocio, lo que limita la cobertura del índice al 83%.

A partir de estas limitaciones se identifican varias líneas de trabajo futuras. La primera es la extensión del análisis a series temporales anuales desde 2019 hasta 2025, lo que multiplicaría las observaciones y permitiría capturar la dinámica temporal del riesgo a través de distintos ciclos. La segunda es la integración de variables macroeconómicas (tipos de interés, prima de riesgo) que contextualicen el riesgo en el entorno económico. La tercera es la ampliación a otros índices europeos (IBEX Medium Cap, FTSE MIB, CAC 40) para evaluar la generalización. La cuarta es el desarrollo de modelos específicos por tipología (financieras vs no financieras) que permitan incorporar ratios propios del sector bancario como CET1 o NPL. La quinta es la incorporación de métodos no lineales como Random Forest o Gradient Boosting una vez se disponga de un dataset suficientemente grande.