

3. TRABAJO TÉCNICO

3.1. Herramientas empleadas

El desarrollo del presente trabajo se ha apoyado en un conjunto de herramientas que dan cobertura a las distintas fases del proyecto: la recopilación y almacenamiento de datos, el procesamiento estadístico y la preparación del dataset final.

El entorno de ejecución del código ha sido Google Colaboratory (Colab), una plataforma de computación en la nube que permite ejecutar código Python desde el navegador sin configuración local. Su elección se justifica por la accesibilidad a recursos computacionales suficientes para el tamaño del dataset, la reproducibilidad mediante la compartición del notebook, y la integración nativa con Google Drive para gestión de archivos.

El lenguaje de programación ha sido Python, estándar de facto en el análisis de datos y el aprendizaje automático. Para la manipulación del dataset se ha utilizado pandas, que permite cargar el archivo Excel mediante `pd.read_excel()`, inspeccionar la estructura con `df.info()` y `df.describe()`, gestionar valores nulos con `df.fillna()` y construir el dataset final para modelización. NumPy ha proporcionado el soporte numérico para operaciones vectoriales y el cálculo de estadísticos como la mediana y el z-score. La visualización se ha realizado con matplotlib y seaborn, librerías que permiten generar histogramas, diagramas de caja, gráficos de dispersión y mapas de calor. La normalización se ha hecho con StandardScaler del módulo `sklearn.preprocessing`, y esta misma librería incluye los modelos de clasificación que se aplicarán en la fase posterior.

Las fuentes de datos primarias han sido Yahoo Finance e Investing.com. Yahoo Finance ha proporcionado los datos bursátiles y ratios de valoración mediante sus páginas de estadísticas clave. Las series históricas de precios diarios necesarias para el cálculo de la volatilidad anualizada y las rentabilidades se han descargado en formato CSV desde Investing.com. Cuando Yahoo Finance no disponía de datos completos de ROE y ROA, se ha utilizado Investing.com como fuente complementaria. En todos los casos se ha trabajado con el último ejercicio anual completo disponible.

3.2. Ingeniería del dato

Esta sección describe el proceso completo de ingeniería del dato llevado a cabo para construir el dataset que sirve de base a los modelos de clasificación. El proceso se ha estructurado en cuatro etapas que siguen la metodología estándar del campo: extracción de datos, exploración y limpieza, transformaciones, y análisis y visualización. Todo el código se encuentra implementado y documentado celda por celda en el notebook adjunto (`Ingenieria_del_Dato_Alonso_Gil.ipynb`), ejecutado íntegramente en Google Colab, y cuyos outputs concretos se reproducen a lo largo de esta sección.

3.2.1. Extracción de datos

La extracción de datos abarca la recopilación de la información financiera de las empresas, su carga en el entorno de análisis y, finalmente, la construcción de la variable objetivo del problema.

El dataset de partida se ha construido recopilando datos financieros públicos de las 29 empresas no financieras del índice IBEX 35 (excluidos los 6 bancos por incompatibilidad con el ICR), con datos actualizados por última vez en abril de 2026. La elección del IBEX 35 como universo de análisis se justifica porque agrupa a las principales empresas cotizadas del mercado español, con datos verificables públicamente, y porque su composición abarca catorce sectores económicos diferentes, lo que aporta diversidad suficiente para que los modelos aprendan patrones generalizables y no específicos de un único sector.

Para cada empresa se han recopilado catorce variables cuantitativas organizadas en cuatro grupos funcionales. En primer lugar, variables bursátiles: la volatilidad anualizada (`Vol_Anual`), calculada como la desviación típica de los rendimientos logarítmicos diarios multiplicada por la raíz cuadrada de 252 días hábiles; la volatilidad trimestral (`Vol_Trim`), calculada del mismo modo sobre los últimos 63 días hábiles; la beta de mercado (`Beta`) frente al IBEX 35; la rentabilidad anual (`Ret_Anual`) calculada como $\text{precio_actual} / \text{precio_hace_252_días} - 1$; y la rentabilidad trimestral (`Ret_Trim`) calculada análogamente sobre 63 días. Las volatilidades y rentabilidades se han calculado a partir de las series históricas descargadas en formato CSV desde Investing.com. En segundo lugar, ratios de valoración: PER (precio sobre beneficio por acción), `Price_Book` (capitalización sobre patrimonio neto) y capitalización bursátil en miles de millones de euros (`Cap_bn`). En tercer

lugar, ratios de rentabilidad: ROE (beneficio neto sobre fondos propios) y ROA (beneficio neto sobre activo total). En cuarto lugar, ratios de solvencia y solidez operativa: margen EBITDA (EBITDA sobre ingresos), Deuda_Capital (deuda financiera total sobre patrimonio neto) y Liquidez_Corriente (activo corriente sobre pasivo corriente). Adicionalmente se ha incluido el precio de cotización (Precio) en euros como variable de referencia. Junto a las variables cuantitativas, cada empresa cuenta con la información de su sector económico (Sector), almacenada como variable cualitativa de texto, que se utilizará exclusivamente para análisis descriptivos sectoriales y no como predictor de los modelos.

El archivo de partida cargado en el notebook (BaseDeDatosTFG.xlsx) contiene 29 filas, una por empresa, y 19 columnas: tres variables de identificación (Empresa, Ticker y Sector, de tipo texto), catorce variables numéricas continuas correspondientes a los indicadores financieros y bursátiles, y dos columnas adicionales con los datos necesarios para construir la variable objetivo: EBIT (beneficio antes de intereses e impuestos) y Gastos_Financieros (gastos financieros netos), extraídos de los Income Statements anuales 2024 publicados en Investing.com y verificables en las cuentas anuales depositadas en la CNMV. Es importante destacar que el dataset de partida no incluye ninguna columna de variable objetivo, lo cual es metodológicamente correcto: la variable Y_RiesgoAlto que queremos predecir debe construirse explícitamente dentro del proceso de ingeniería del dato a partir de los datos disponibles, y no importarse de un trabajo previo. Esta construcción se detalla a continuación.

Construcción de la variable objetivo Y_RiesgoAlto: Interest Coverage Ratio (ICR).

La construcción de la variable objetivo constituye la decisión metodológica más importante del trabajo, ya que condiciona toda la fase posterior de modelización. En la versión definitiva del trabajo el riesgo se operacionaliza mediante el Interest Coverage Ratio ($ICR = EBIT / \text{Gastos Financieros}$), un indicador que mide directamente la capacidad de una empresa para cubrir sus obligaciones de deuda con su beneficio operativo y que resuelve de raíz cualquier circularidad metodológica: el EBIT y los Gastos Financieros no forman parte de los 14 predictores del modelo, garantizando la independencia matemática total entre el target y los predictores.

La construcción del score se sustenta en la literatura clásica de predicción de tensión financiera. Beaver (1966) identificó el ratio de cobertura de flujos como el predictor más potente de quiebra empresarial. Altman (1968) incorporó el EBIT en su Z-score precisamente por su capacidad para capturar la tensión entre generación de beneficio y carga financiera. La ventaja del ICR es su claridad conceptual: una empresa con ICR inferior a 1 no cubre sus intereses con su beneficio operativo. Cabe matizar que el score utilizado en este trabajo no replica el Z-score original de Altman ni el O-score de Ohlson en sus variables ni en sus pesos específicos: estos modelos clásicos utilizan ratios concretos (como Working Capital/Total Assets o Retained Earnings/Total Assets) que no estaban disponibles de forma sistemática en la literatura financiera aplicada al contexto español.

El procedimiento de cálculo del ICR ha sido el siguiente. Los datos de EBIT y Gastos_Financieros forman parte del dataset de entrada (BaseDeDatosTFG.xlsx), extraídos de los Income Statements anuales 2024 de Investing.com y verificados contra las cuentas anuales publicadas en la CNMV. El ICR se calcula directamente en el notebook como el cociente $ICR = EBIT / Gastos_Financieros$ para cada una de las 29 empresas. Este diseño garantiza la trazabilidad completa de los datos: cualquier revisor puede verificar los valores de EBIT y Gastos_Financieros abriendo el Excel de entrada sin necesidad de acceder al código. A continuación se dicotomiza por la mediana: se asigna $Y = 1$ (riesgo ALTO) a las empresas con ICR inferior a la mediana e $Y = 0$ (riesgo BAJO) a las que la superan. La elección de la mediana como umbral garantiza una distribución equilibrada entre las dos clases. Es importante subrayar que ni el EBIT ni los Gastos Financieros se incluyen en ningún momento entre las 14 variables predictoras del modelo: ambos son exclusivos de la construcción del target.

La fórmula del target, tal como se implementa en el notebook, es:

$$ICR = EBIT / Gastos_Financieros$$

$Y_RiesgoAlto = 1$ si $ICR < mediana(ICR) = 4,22$; $Y = 0$ en caso contrario.

El umbral de corte resultante es de 4,22 (mediana del ICR). La distribución obtenida es de 14 empresas clasificadas como riesgo ALTO (48,3%) y 15 como riesgo BAJO (51,7%), lo que garantiza el equilibrio entre clases necesario para el entrenamiento posterior de los modelos.

Sobre la ausencia de circularidad metodológica.

El diseño con ICR garantiza la ausencia total de circularidad metodológica. Las dos variables que componen el ICR (EBIT y Gastos Financieros) no forman parte de los 14 predictores del modelo. No existe ninguna relación matemática directa entre el target y los predictores: predecir la capacidad de cobertura de deuda de una empresa a partir de sus indicadores de mercado y sus ratios contables es un ejercicio genuinamente predictivo. El experimento de robustez de la sección 3.3.7 de la memoria de Análisis del Dato confirma esto empíricamente: cuando se sustituyen las etiquetas reales por etiquetas aleatorias (escenario placebo), la precisión cae desde el 79,3% hasta el 58,6%, una diferencia de 20,7 puntos que demuestra que los modelos aprenden señal real, no memorizan nada trivial.

Naturaleza relativa de la clasificación.

Una segunda observación importante sobre la operacionalización del riesgo es que la clasificación resultante es de naturaleza relativa al universo analizado, no absoluta. Al utilizar la mediana del ICR como umbral de corte (4,22), la asignación de cada empresa a la clase ALTO o BAJO depende de la distribución conjunta de las 29 empresas no financieras del IBEX 35 actual. Si se añadiera una empresa nueva al dataset, la mediana del ICR se desplazaría y la clasificación de algunas empresas próximas al umbral podría modificarse. Esto significa que el modelo entrenado en este trabajo es directamente aplicable al universo del IBEX 35 en su composición actual, pero su extensión a empresas externas al índice o a versiones futuras del IBEX 35 con cambios significativos en su composición requeriría recalibrar el umbral de la mediana del ICR sobre el nuevo universo. Esta limitación es consustancial a cualquier operacionalización basada en estadísticos relativos al dataset y se reconoce explícitamente en las líneas futuras del trabajo.

Empresas con mayor y menor riesgo ICR.

A continuación se muestran las cinco empresas con mayor ICR (clasificadas como riesgo BAJO) y las cinco con menor ICR (clasificadas como riesgo ALTO), junto con sus valores de EBIT, Gastos Financieros e ICR. Estos resultados permiten validar visualmente que la clasificación es financieramente coherente.

Empresa	Sector	Deuda/Cap	ROA	Liq.Corr.	EBITDA%
---------	--------	-----------	-----	-----------	---------

Laboratorios Rovi	Salud	0,18	12,11	3,13	26,30
Aena	Infraestructuras	0,83	12,30	1,88	58,07
Inditex	Consumo	0,29	17,70	1,54	23,60
Merlin Properties	Inmobiliario	0,63	5,70	1,18	75,42
Amadeus IT	Tecnología	0,67	11,50	0,82	37,55

Tabla 1. Top 5 empresas con mayor ICR (menor riesgo de cobertura de deuda).

Empresa	Sector	Deuda/Cap	ROA	Liq.Corr.	EBITDA%
Telefónica	Telecom	2,35	-4,30	0,89	19,79
Sacyr	Construcción	3,85	1,80	1,04	26,29
ACS	Construcción	2,99	2,80	1,16	4,23
Acciona	Construcción	2,15	1,98	1,19	8,84
IAG (Iberia)	Transporte	1,88	7,70	0,70	18,98

Tabla 2. Top 5 empresas con menor ICR (mayor riesgo de cobertura de deuda).

Las empresas con mayor ICR corresponden a compañías que generan un beneficio operativo muy superior a sus gastos financieros: Laboratorios Rovi tiene un ICR de 89,80, lo que significa que su EBIT cubre casi 90 veces sus gastos financieros, reflejo de una empresa prácticamente libre de deuda; Logista (ICR 38,42) e Inditex (ICR 25,30) presentan patrones similares; Mapfre (ICR 17,22) y Amadeus IT (ICR 15,13) cierran el top 5 con ICR muy holgados. En el extremo opuesto, Cellnex Telecom presenta el ICR más bajo del universo (0,74): su EBIT de 583,76 millones es inferior a sus Gastos Financieros de 788,23 millones, lo que significa que no genera beneficio operativo suficiente para cubrir sus intereses, consecuencia de su agresiva estrategia de expansión mediante adquisiciones apalancadas. Las constructoras ACS (1,20), Acciona (1,55) y Sacyr (1,62) también presentan ICR muy bajos, coherente con el alto apalancamiento estructural del sector. Esta coherencia entre el ICR y el conocimiento financiero cualitativo de las empresas valida la construcción de la variable objetivo.

Nota sobre las entidades financieras excluidas.

Los seis bancos del IBEX 35 (Banco Santander, BBVA, CaixaBank, Banco Sabadell, Bankinter y Unicaja Banco) han sido excluidos del universo analizado porque el Interest Coverage Ratio no es aplicable a su modelo de negocio. Esta exclusión requiere una justificación técnica detallada dada su relevancia cuantitativa: los seis bancos representan conjuntamente el 17% del índice por capitalización bursátil. La razón de la exclusión es estructural y no metodológica. En una empresa no financiera, el EBIT recoge el beneficio generado por la actividad operativa antes de atender las cargas financieras; los Gastos Financieros representan el coste de la deuda que debe cubrirse con ese beneficio. El ICR mide, por tanto, cuántas veces la empresa puede pagar sus intereses con su resultado operativo, lo que constituye una medida directa de la capacidad de solvencia a corto y medio plazo. En una entidad bancaria, sin embargo, los intereses no son un gasto sino el principal ingreso del negocio. El margen de intereses (diferencia entre intereses cobrados a clientes e intereses pagados por depósitos y financiación mayorista) es la partida de ingresos más importante de cualquier banco. Calcular $ICR = EBIT / Gastos_Financieros$ para un banco produciría un cociente sin interpretación financiera comparable a la de una empresa industrial o de servicios: el denominador (Gastos_Financieros) no representa una carga que el banco debe cubrir con su actividad, sino una parte consustancial de su modelo de negocio de intermediación. Adicionalmente, las entidades financieras presentan nullos estructurales en tres de las catorce variables predictoras del modelo (Deuda_Capital, Liquidez_Corriente y EBITDA_Margin), porque estos ratios no tienen aplicabilidad directa en el balance y la cuenta de resultados bancarios. Su inclusión habría requerido imputaciones que carecerían de interpretación financiera coherente. La consecuencia práctica de esta decisión es que el universo analizado son las 29 empresas no financieras del IBEX 35, que representan el 83% del índice y abarcan trece sectores económicos distintos, proporcionando diversidad sectorial suficiente para el entrenamiento de los modelos. La exclusión de los bancos es una limitación reconocida del trabajo y se identifica explícitamente como la primera línea futura de investigación: el desarrollo de un sistema de scoring de riesgo específico para entidades financieras debería basarse en métricas propias del sector bancario, como el ratio de capital CET1 (Capital de Nivel 1 Ordinario), el ratio de morosidad o Non-Performing Loans (NPL), el ratio de cobertura de provisiones, o el ratio de liquidez a corto plazo (LCR), todos ellos

regulados por Basilea III y publicados trimestralmente por las entidades en sus informes de gestión.

3.2.2. Exploración y limpieza

Una vez cargado el dataset y construida la variable objetivo, se ha procedido a la exploración y limpieza del conjunto, que comprende la validación de unicidad, el análisis de la distribución de las variables, el tratamiento de valores nulos y la detección de valores atípicos.

La primera comprobación ha sido verificar que no existen registros duplicados, lo que introduciría un sesgo artificial al dar más peso a una observación. El output del notebook confirma 0 filas duplicadas y 0 tickers duplicados, garantizando que cada fila corresponde a una empresa distinta.

La inspección de tipos de datos mediante `df.info()` confirma que Empresa, Ticker y Sector son de tipo object (texto), y las catorce variables numéricas son de tipo float64. Esta distribución de tipos es la esperada y confirma que la carga del archivo Excel ha interpretado correctamente cada columna.

Análisis de la distribución de las variables.

Antes de proceder al tratamiento de valores nulos y atípicos, resulta imprescindible examinar la distribución de cada variable numérica para entender la forma de los datos, identificar visualmente posibles asimetrías o concentraciones extremas, y preparar las decisiones metodológicas que se tomarán a continuación. Para ello se han construido los histogramas de las catorce variables, junto con la indicación de la media (línea negra discontinua) y la mediana (línea gris punteada) en cada distribución.

Distribución de las 14 variables numéricas
(rojo: variables que componen el Score de Fragilidad)




Ilustración 1. Histogramas de las 14 variables numéricas. En rojo, las variables con mayor correlación con el ICR.

El análisis de los histogramas permite identificar varios patrones relevantes. En primer lugar, las distribuciones presentan un grado importante de asimetría positiva en algunas variables, especialmente notable en Cap_bn, Precio, PER, Price_Book y Deuda_Capital: la mayoría de las empresas se concentran en valores bajos o intermedios y existe una cola larga hacia la derecha con unos pocos casos extremos. Esta asimetría refleja la heterogeneidad estructural del IBEX 35, donde conviven empresas de capitalización muy distinta y modelos de negocio con apalancamientos muy diferentes. En segundo lugar, la diferencia entre la media y la mediana es especialmente notable en estas variables asimétricas (por ejemplo, en Cap_bn la media es 30,77 frente a la mediana de 13,07), lo que confirma que la mediana es el estadístico de tendencia central más representativo del conjunto cuando hay valores extremos, y justifica su uso tanto en la imputación de nulos como en el umbral del score. En

tercer lugar, los rangos de las distintas variables son radicalmente distintos: Cap_bn oscila entre 2,80 y 158,20, mientras que Vol_Anual lo hace entre 0,16 y 0,55. Esta diferencia de escalas refuerza la necesidad de la normalización con StandardScaler que se aplicará en la siguiente sección. En cuarto lugar, las variables con mayor correlación con el ICR (Deuda_Capital, ROE, ROA, destacadas en rojo) presentan distribuciones con variabilidad suficiente para capturar diferencias relevantes entre empresas, validando su capacidad discriminante.

Análisis de valores nulos.

El análisis de valores nulos sobre las catorce variables numéricas del modelo identifica un total de 4 valores nulos distribuidos en cuatro variables, sobre un total de 406 celdas posibles ($29 \text{ empresas} \times 14 \text{ variables}$), lo que representa un 1,0% del total. Al excluir los seis bancos, los 18 nulos estructurales que estos generaban han desaparecido, quedando únicamente nulos genuinos. Antes de decidir cómo tratar estos nulos, es imprescindible identificar las empresas afectadas y comprender el motivo de la ausencia de datos.

La inspección de empresas con al menos un nulo revela un patrón estructural justificable: Redeia presenta nulos en Deuda_Capital y Liquidez_Corriente porque estos datos no estaban disponibles en las fuentes consultadas en el momento de la extracción; Mapfre presenta nulo en EBITDA_Margin porque como aseguradora este ratio no tiene la misma aplicabilidad que en empresas industriales; y Puig Brands presenta nulo en Beta por su reciente salida a bolsa en mayo de 2024, con menos de un año de historial bursátil. Esto se debe a que estas variables no son aplicables al modelo de negocio de las entidades financieras y aseguradoras por las siguientes razones técnicas. El EBITDA_Margin es un concepto propio de empresas industriales o de servicios con costes de producción identificables, pero los bancos generan sus ingresos a través de márgenes de interés, comisiones y otras fuentes de naturaleza estrictamente financiera. La Deuda_Capital pierde su significado habitual en bancos porque los depósitos de clientes se contabilizan como pasivo financiero, lo que haría que el ratio fuese extremadamente elevado por construcción y completamente incomparable con el de una empresa industrial. La Liquidez_Corriente no se calcula para bancos porque su balance no distingue entre activos y pasivos corrientes en

el sentido convencional, ya que toda la operativa tiene naturaleza financiera a distintos plazos.

El caso de Redeia es diferente: dispone de EBITDA_Margin (62,08%) pero no de Deuda_Capital ni Liquidez_Corriente, lo que se debe a que en las fuentes consultadas estos datos concretos no estaban disponibles en el momento de la extracción. El caso de Mapfre, aseguradora, es análogo al de los bancos para EBITDA_Margin, pero sí dispone de Deuda_Capital (0,26) y Liquidez_Corriente (1,29) porque su estructura de balance tiene componentes más próximos a los de una empresa no financiera. El único nulo en la variable Beta corresponde a Puig Brands. Esta empresa realizó su Oferta Pública de Venta en mayo de 2024, por lo que al cierre del periodo analizado contaba con menos de un año de historial bursátil, tiempo insuficiente para que las fuentes de datos puedan calcular una beta mensual con la ventana de cinco años que utilizan como estándar.

Decisión de tratamiento de nulos.

La decisión adoptada para el tratamiento de todos los nulos identificados ha sido la imputación con la mediana de cada variable, calculada sobre las observaciones no nulas del mismo dataset. Se ha descartado la eliminación de filas porque con un dataset de 29 empresas cualquier eliminación reduce la representatividad del conjunto. Se ha descartado también la eliminación de columnas porque EBITDA_Margin, Deuda_Capital y Liquidez_Corriente son variables con información predictiva real para las empresas no financieras.

Se ha optado por la mediana en lugar de la media como estadístico de imputación por su robustez frente a valores extremos. Como ya se observó en los histogramas anteriores, algunas variables presentan distribuciones asimétricas con valores extremos reales como ACS con Deuda_Capital de 2,99, Sacyr con 3,85 o Acciona con 2,15. Si se utilizase la media, estos valores extremos desplazarían artificialmente hacia arriba el valor de imputación. Los valores de imputación obtenidos en el notebook son: mediana de Beta = 0,7500; mediana de EBITDA_Margin = 23,8450%; mediana de Deuda_Capital = 0,9200; mediana de Liquidez_Corriente = 1,1650.

Las cuatro imputaciones corresponden a empresas con nulos estructurales o técnicos bien justificados: dos de Redeia (datos no disponibles), una de Mapfre (EBITDA_Margin no

aplicable a aseguradoras en sentido estricto) y una de Puig Brands (Beta no calculable con menos de un año de historial).

Detección y tratamiento de valores atípicos.

La detección de outliers se ha realizado mediante el método del rango intercuartílico (IQR), que identifica como atípico cualquier valor superior a $Q3 + 1,5 \cdot IQR$ o inferior a $Q1 - 1,5 \cdot IQR$. Se trata del método más robusto para datasets de tamaño moderado, ya que no asume normalidad ni se ve influido por los propios valores extremos en el cálculo de los límites. Se han identificado 29 valores atípicos distribuidos en 11 de las 14 variables. Un análisis detallado permite concluir que todos son valores reales y justificables, no errores de introducción, como pueden apreciarse visualmente en los histogramas anteriores donde se muestran las colas que producen estos outliers.

Solaria aparece como outlier en cuatro variables simultáneamente: su volatilidad anual (0,5458) es la más alta del dataset, su rentabilidad anual del 251% es extraordinaria, y su margen EBITDA del 85,71% es el más elevado del conjunto. Todos estos valores son coherentes con el perfil de una empresa de generación solar de pequeño tamaño, muy sensible a cambios regulatorios. ArcelorMittal presenta una beta de 1,71, la más alta del dataset, porque es una empresa de materiales cíclicos cuya cotización amplifica los movimientos del mercado. Telefónica, Cellnex y Acerinox presentan PER y ROE negativos por pérdidas netas en el último ejercicio. ACS y Sacyr tienen ratios de Deuda_Capital de 2,99 y 3,85, elevados pero típicos del modelo de negocio de constructoras e infraestructuras. Las cuatro mayores capitalizaciones del IBEX 35 son outliers en Cap_bn por su posición de liderazgo europeo.

La decisión adoptada es mantener todos los outliers, apoyada en dos argumentos. En primer lugar, todos son valores reales verificados en las fuentes originales; eliminarlos empobrecería el dataset al perder información genuina. En segundo lugar, con solo 35 observaciones, eliminar cualquier fila tiene un coste elevado en términos de representatividad.

3.2.3. Transformaciones

Una vez limpio el dataset, se han aplicado dos transformaciones preparatorias antes de la modelización: la normalización de las variables numéricas y el análisis de correlaciones con la variable objetivo.

Normalización con StandardScaler.

Como se ha podido comprobar en el análisis de los histogramas, las variables del dataset están en escalas radicalmente diferentes. La capitalización bursátil oscila entre 2,80 y 158,20 miles de millones de euros, mientras que la volatilidad anual se mueve entre 0,16 y 0,55. Si los modelos recibiesen las variables en su escala original, darían artificialmente mucho más peso a Cap_bn por su mayor magnitud numérica, sin fundamento financiero.

La normalización se ha realizado mediante el StandardScaler de scikit-learn, que aplica la transformación $z = (x - \mu) / \sigma$ a cada variable. El resultado es que cada variable tiene media 0 y desviación típica 1. Esta transformación es necesaria para la regresión logística y el análisis discriminante lineal, que son sensibles a la escala. El árbol de decisión no la requiere, pero se le aplica para mantener la consistencia del pipeline.

Análisis de correlaciones con la variable objetivo.

Una vez normalizado el dataset, se ha calculado la correlación de Pearson entre cada variable independiente y Y_RiesgoAlto. El ranking obtenido es el siguiente, ordenado por valor absoluto descendente:

Variable	r	Dirección financiera
ROA	-0,5076	Sí
EBITDA_Margin	+0,2310	Sí
Deuda_Capital	+0,5456	Sí
Liquidez_Corriente	-0,0877	Sí
PER	-0,2549	No
Vol_Anual	+0,1178	No
Precio	+0,0856	No
Cap_bn	-0,3507	No
Ret_Anual	+0,1979	No
ROE	-0,5254	No
Beta	+0,2132	No
Price_Book	-0,2689	No

Vol_Trim	-0,0375	No
Ret_Trim	+0,0120	No

Tabla 3. Correlación de Pearson de cada variable con Y_RiesgoAlto.

Con el target ICR, todas las correlaciones son genuinamente informativas porque ninguna variable forma parte de la fórmula del target. El ranking es financieramente coherente. Deuda_Capital ($r = +0,55$) encabeza el ranking con signo positivo: empresas muy endeudadas tienden a tener más gastos financieros y por tanto menor ICR. ROE ($r = -0,53$) y ROA ($r = -0,51$) le siguen con signo negativo: mayor rentabilidad implica mayor EBIT y por tanto mayor ICR y menor riesgo. Cap_bn ($r = -0,35$) muestra que las empresas de mayor capitalización tienden a tener mejor cobertura de deuda. Es relevante que EBITDA_Margin tenga correlación positiva (+0,23): esto puede parecer contraintuitivo, pero es estadísticamente correcto, ya que empresas con altos márgenes (como Cellnex, con EBITDA_Margin elevado pero ICR de 0,74 por su alto endeudamiento) pueden tener ICR bajo si la deuda es muy grande. Deuda_Capital domina sobre EBITDA_Margin en la predicción del ICR. Las variables bursátiles (Beta +0,21, Vol_Anuar +0,12) también tienen correlaciones apreciables y en el sentido esperado: mayor riesgo bursátil se asocia con mayor riesgo financiero, aunque de forma secundaria.

Las diez variables restantes son externas a la construcción del score y constituyen información empírica genuina sobre la capacidad predictiva incremental que pueden aportar las señales de mercado. PER ($r = -0,2666$) muestra una correlación apreciable; Vol_Anuar ($r = +0,1342$) y Beta ($r = +0,0692$) muestran correlaciones más débiles individualmente. Estas correlaciones marginales son coherentes con la idea de que las variables de mercado, aunque no expliquen por sí solas la mayor parte del riesgo fundamental, sí pueden aportar información complementaria cuando se combinan con los ratios contables en un modelo multivariante. Esta hipótesis se verifica en la fase de análisis del dato, donde los modelos predictivos que combinan las catorce variables alcanzan capacidad predictiva sustancial sobre Y_RiesgoAlto.




Ilustración 2. Correlación de Pearson con Y_RiesgoAlto (ICR). Deuda_Capital, ROE y ROA son los predictores con mayor correlación.

3.2.4. Análisis y visualización

La etapa final de visualización ha producido varias representaciones gráficas que permiten documentar los patrones del dataset, validar visualmente la construcción de la variable objetivo y complementar los estadísticos numéricos descritos anteriormente.




Ilustración 3. ICR por empresa (rojo = ALTO riesgo, azul = BAJO riesgo).

La distribución del Score de Fragilidad ordenada permite visualizar la lógica de la clasificación: empresas a la izquierda del umbral son BAJO riesgo, a la derecha ALTO. La línea discontinua marca el umbral ICR = 4,22. Las empresas en rojo (ALTO) se concentran en la mitad inferior del gráfico.

Validación visual de la separación entre clases.

Una validación adicional de la calidad de la variable objetivo construida consiste en comparar mediante diagramas de caja la distribución de cada una de las cuatro variables del score por separado, agrupando las empresas en las dos clases ALTO y BAJO. Si la construcción del score es financieramente coherente, las distribuciones de cada variable deberían diferir sustancialmente entre las dos clases.




Ilustración 4. Distribución de las 4 variables más correlacionadas con el ICR por clase de riesgo.

Los diagramas de caja confirman visualmente que la separación entre las dos clases es notable en las cuatro dimensiones del score. En *Deuda_Capital*, la mediana del grupo ALTO (en torno a 1,05) duplica claramente a la mediana del grupo BAJO (en torno a 0,80), y el rango intercuartílico del grupo ALTO se extiende muy por encima del rango BAJO, alcanzando casi el valor 4 en su outlier superior (Sacyr). En *ROA*, la situación se invierte: el grupo BAJO presenta una mediana en torno al 5,5%, mientras que el grupo ALTO se concentra alrededor del 1% con algunos casos negativos. La separación es también clara en *EBITDA_Margin*, donde el grupo BAJO alcanza medianas en torno al 30% frente al 20% del grupo ALTO, con una variabilidad mucho mayor en el grupo BAJO que llega hasta valores superiores al 80%. *Liquidez_Corriente* muestra una separación más sutil pero coherente: el grupo BAJO tiene mediana ligeramente superior y mayor variabilidad. Estas diferencias visuales confirman que la clasificación binaria del riesgo construida a partir del score captura patrones reales en las cuatro dimensiones financieras consideradas, y no es una asignación artificial o circular.




Ilustración 5. Perfil medio por nivel de riesgo ICR.

El análisis comparativo por nivel de riesgo confirma diferencias claras en las variables clave: empresas ALTO presentan Deuda_Capital medio de 1,66 frente al 0,71 de las BAJO; ROA medio de 2,59% frente a 6,97%; EBITDA_Margin de 36,01% frente a 25,38%; Liquidez de 1,21 frente a 1,31. En las variables de mercado las diferencias son más modestas pero coherentes: empresas ALTO presentan Beta media de 0,84 frente a 0,67 del grupo BAJO.

Mapa bidimensional del riesgo fundamental.

Para validar visualmente la clasificación ICR, se ha construido un gráfico de dispersión que sitúa cada una de las 29 empresas en el plano definido por las dos variables con mayor correlación con el ICR: Deuda_Capital en el eje horizontal y ROE en el eje vertical. Cada empresa se representa como un punto coloreado según su clase Y_RiesgoAlto (rojo para ALTO, azul para BAJO) y se identifica con su nombre.

4,10), Redeia (ICR 4,22), Enagás (ICR 2,71) y Ferrovial (ICR 2,09) están en zona frontera. Estas empresas son las que generarán más errores de clasificación, como se documenta en la memoria de Análisis del Dato.




Ilustración 7. Matriz de correlación entre las 14 variables y Y_RiesgoAlto.

La matriz de correlación completa permite identificar también las correlaciones internas entre predictores. Se observa una correlación elevada entre Vol_Anual y Vol_Trim (0,86), esperable porque ambas miden volatilidad en distintos horizontes. La correlación entre ROA y ROE es moderada, ya que cada uno mide la rentabilidad sobre una base distinta. La capitalización bursátil Cap_bn presenta correlaciones bajas con la mayoría de variables, reflejando que el tamaño absoluto no determina el perfil financiero.

La distribución equilibrada de Y_RiesgoAlto, con 15 BAJO (51,7%) y 14 ALTO (48,3%), es óptima para los modelos de clasificación al evitar problemas de class imbalance. El resultado final del proceso es un dataset de 29 observaciones y 19 columnas (las 17

originales más ICR e Y_RiesgoAlto añadidas en el proceso), completamente libre de valores nulos, con las variables numéricas escaladas a media 0 y desviación típica 1. Este dataset se exporta al archivo Dataset_Final_ICR_IBEX35.xlsx y constituye el input directo para la fase de análisis del dato. El dataset exportado contiene 29 observaciones y 19 columnas: los 3 identificadores, las 14 variables numéricas normalizadas, el ICR sin normalizar (para interpretación) y Y_RiesgoAlto. Las columnas EBIT y Gastos_Financieros no se incluyen en el dataset de modelización porque cumplieron su función al construir el target y no son predictores del modelo.